



Universidade Federal de Alagoas – UFAL
Instituto de Computação – **IC**

Aprendizagem de Máquina e Construção de **Base de Conhecimento**:

Indução de Árvore de Decisão

Evandro de Barros Costa
evandro@ic.ufal.br

Maceió, Alagoas
Agosto, 2026

Um Problema Motivador

Suponha que um gerente de um determinado banco, contratasse você para desenvolver um Sistema de Software Inteligente para cumprir a tarefa de decidir sobre o nível de risco oferecido por usuários que buscam empréstimo de dinheiro, a cada demanda de seus clientes.

Considere 3 categorias de risco na classificação dos clientes: Alto, Moderado e Baixo.

Considere disponível uma **base de dados** com história de clientes, como a seguir.

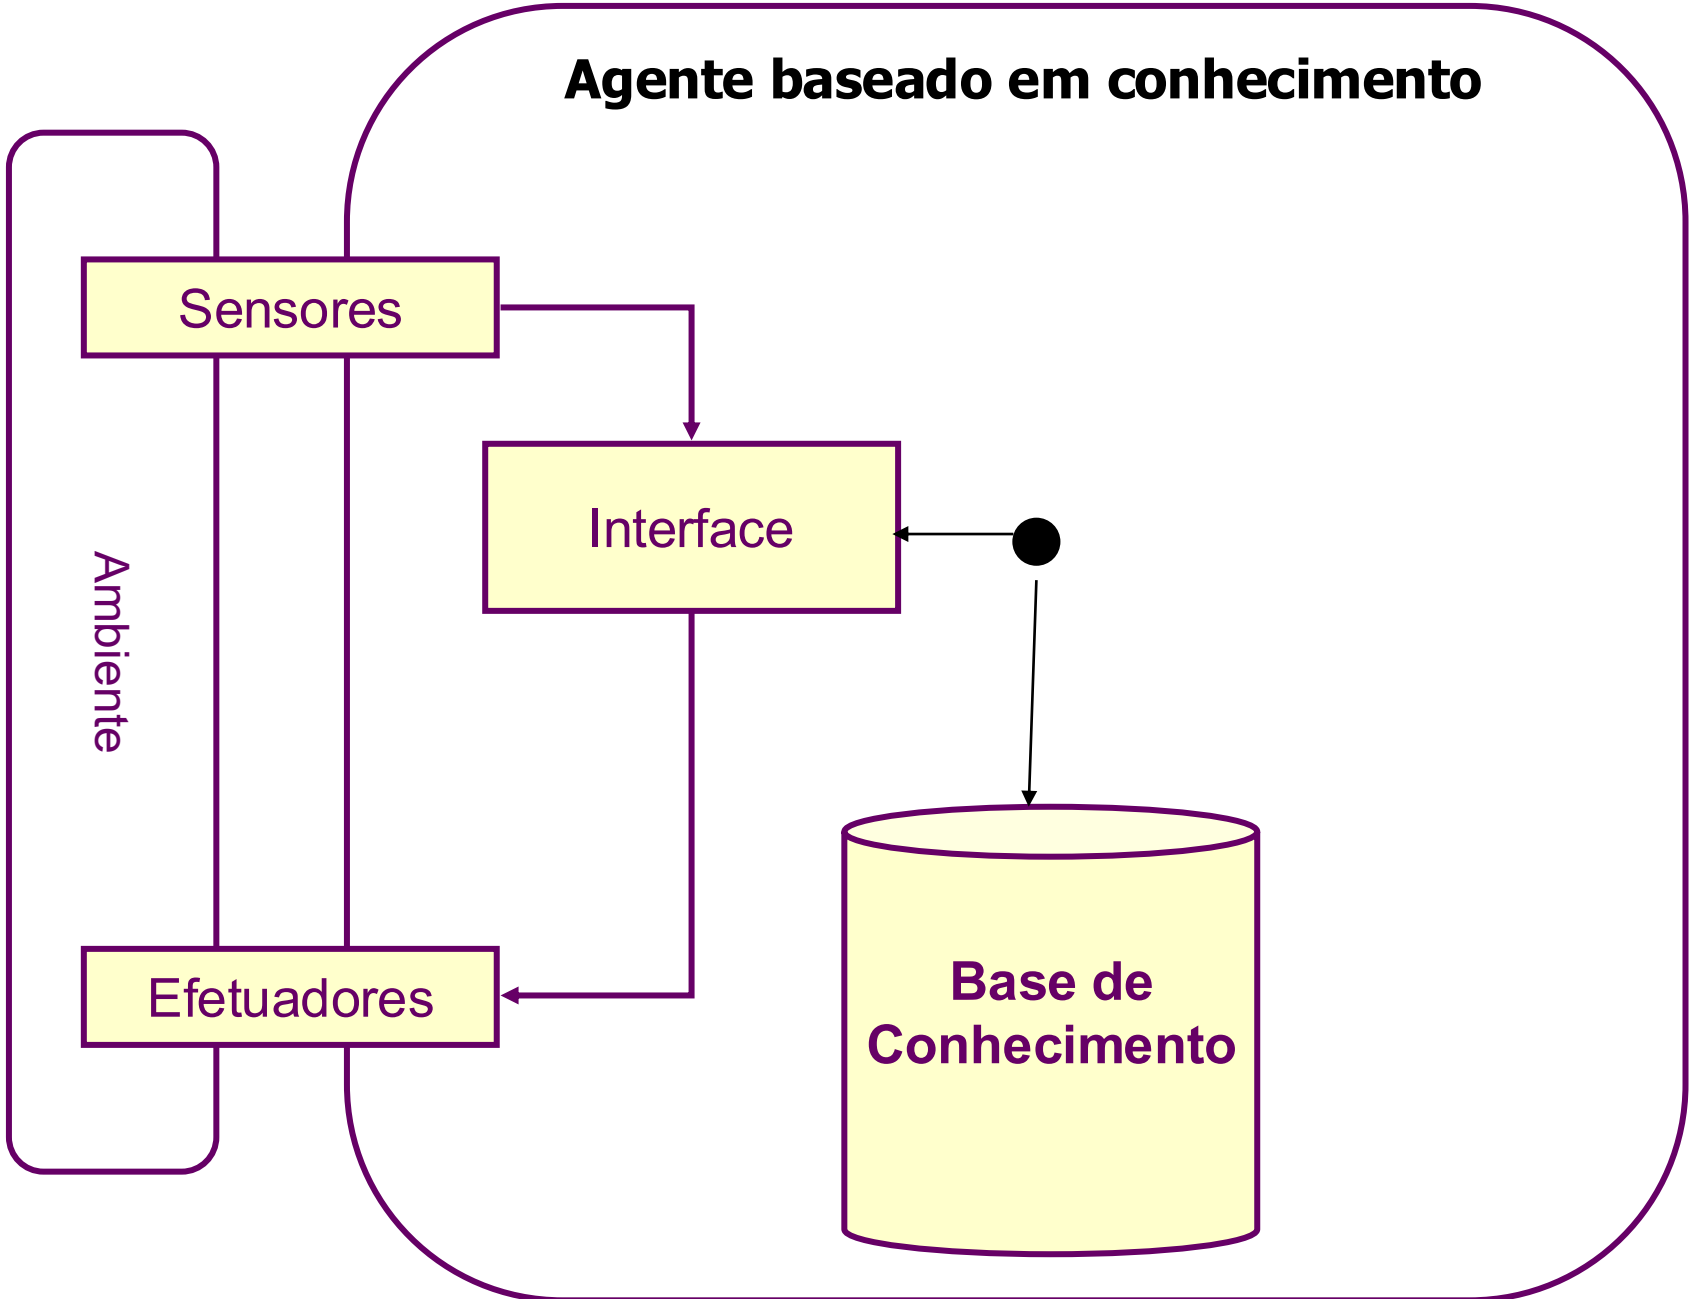
Em Busca da Solução

- Do ponto de vista técnico e agora já sabendo que se trata de uma tarefa de **Classificação**, envolvendo **aprendizado de máquina** (Machine Learning), por onde iniciar?

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **5 atributos e 3 classes** (Baseado no livro do Luger: IA)

	Historia de Crédito	Dívida	Serasa	Garantia	Renda	Risco
E1	Ruim	Alta	Sim	Nenhuma	$0 a $15k	Alto
E2	Desconhecida	Alta	Sim	Nenhuma	$15 a $35k	Alto
E3	Desconhecida	Baixa	Não	Nenhuma	$15 a $35k	Moderado
E4	Desconhecida	Baixa	Não	Nenhuma	$0 a $15k	Alto
E5	Desconhecida	Baixa	Não	Nenhuma	Acima de $35k	Baixo
E6	Desconhecida	Baixa	Sim	Adequada	Acima de $35k	Baixo
E7	Ruim	Baixa	Sim	Nenhuma	$0 a $15k	Alto
E8	Ruim	Baixa	Não	Adequada	Acima de $35k	Moderado
E9	Boa	Baixa	Não	Nenhuma	Acima de $35k	Baixo
E10	Boa	Alta	Sim	Adequada	Acima de $35k	Baixo
E11	Boa	Alta	Não	Nenhuma	$0 a $15k	Alto
E12	Boa	Alta	Não	Nenhuma	$15 a $35k	Moderado
E13	Boa	Alta	Sim	Nenhuma	Acima de $35k	baixo
E14	Ruim	Alta	Não	Nenhuma	$15 a $35k	Alto


Agente baseado em conhecimento
Sensores
Interface
Ambiente
Efetuadores
Base de
Conhecimento

Contexto da aula em relação à arquitetura conceitual

Foco: Componente **Base de Conhecimento (BC)** da arquitetura conceitual para um Agente Baseado em Conhecimento.

Técnica: Uso de aprendizagem de máquina (**AM**) supervisionada.

Técnica a ser aprendida: Aprendizagem de Árvore de Decisão (**AD**) , usando inferência indutiva.

Aprendizagem de Máquina Supervisionada

Indução de Árvore de Decisão

Propósito central da aula

Como construir automaticamente, usando técnica de AM, uma **base de conhecimento (BC)** a partir de **dados**, considerando tal **BC** como um componente de um **agente baseado em conhecimento**?

Aprendizagem de Máquina Supervisionada

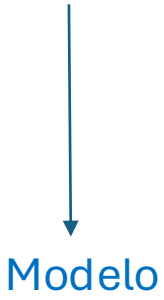
Dados → Modelo: AD (Base de Conhecimento)

↓

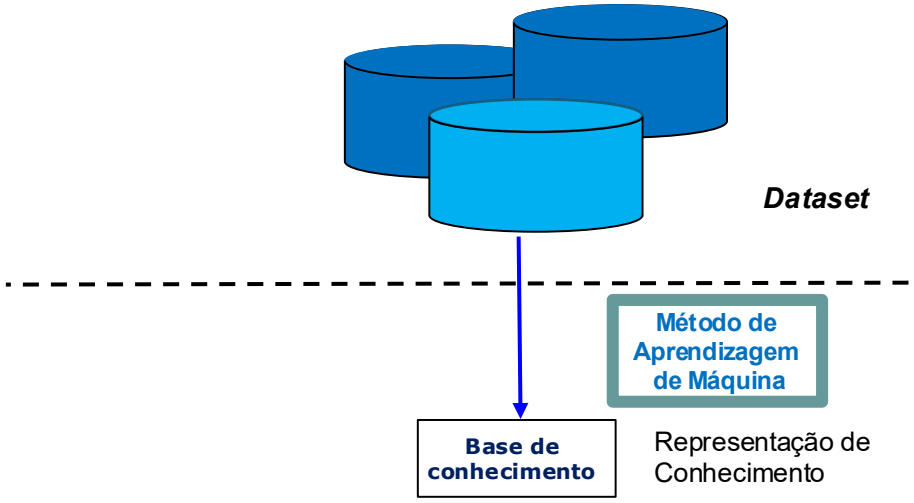
Árvore de Decisão ou regras, ...

Construção Automática da Base Conhecimento

Dados



Modelo



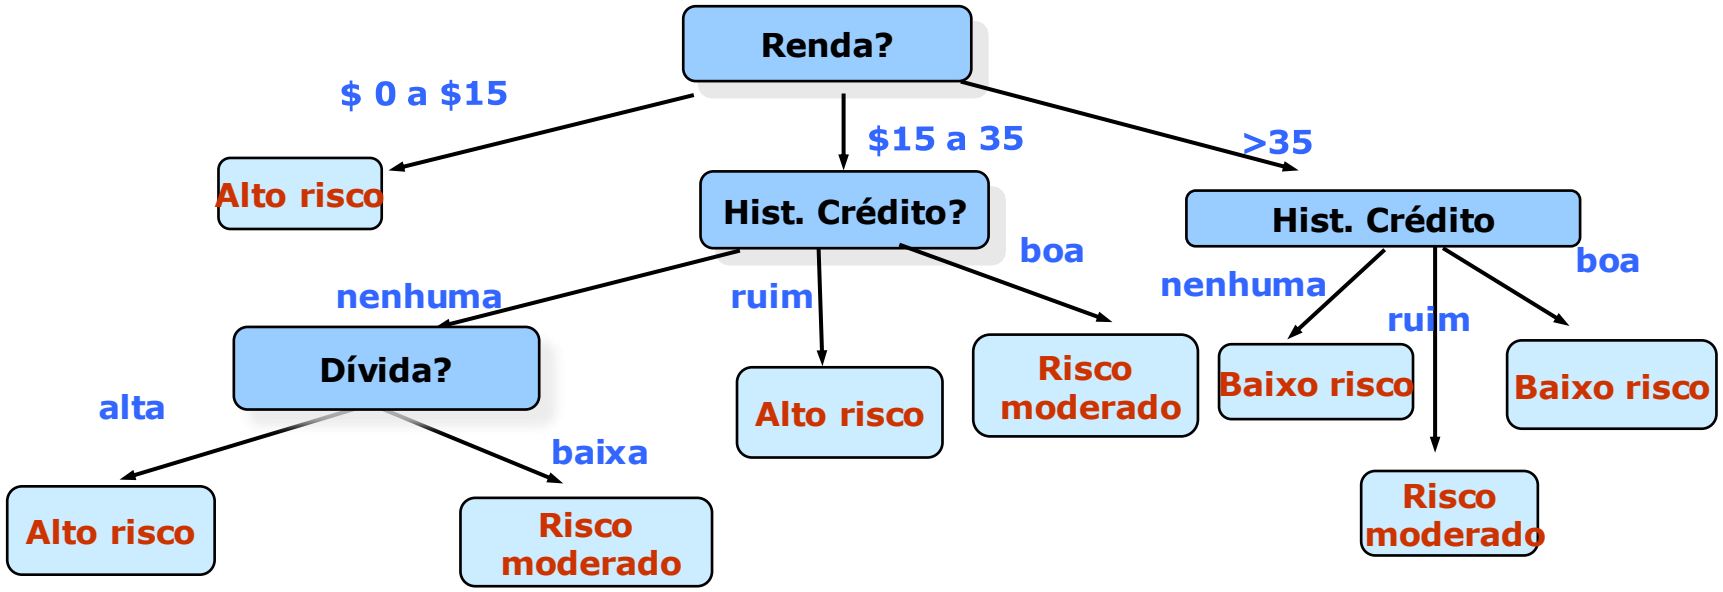
Indução de Árvore de Decisão

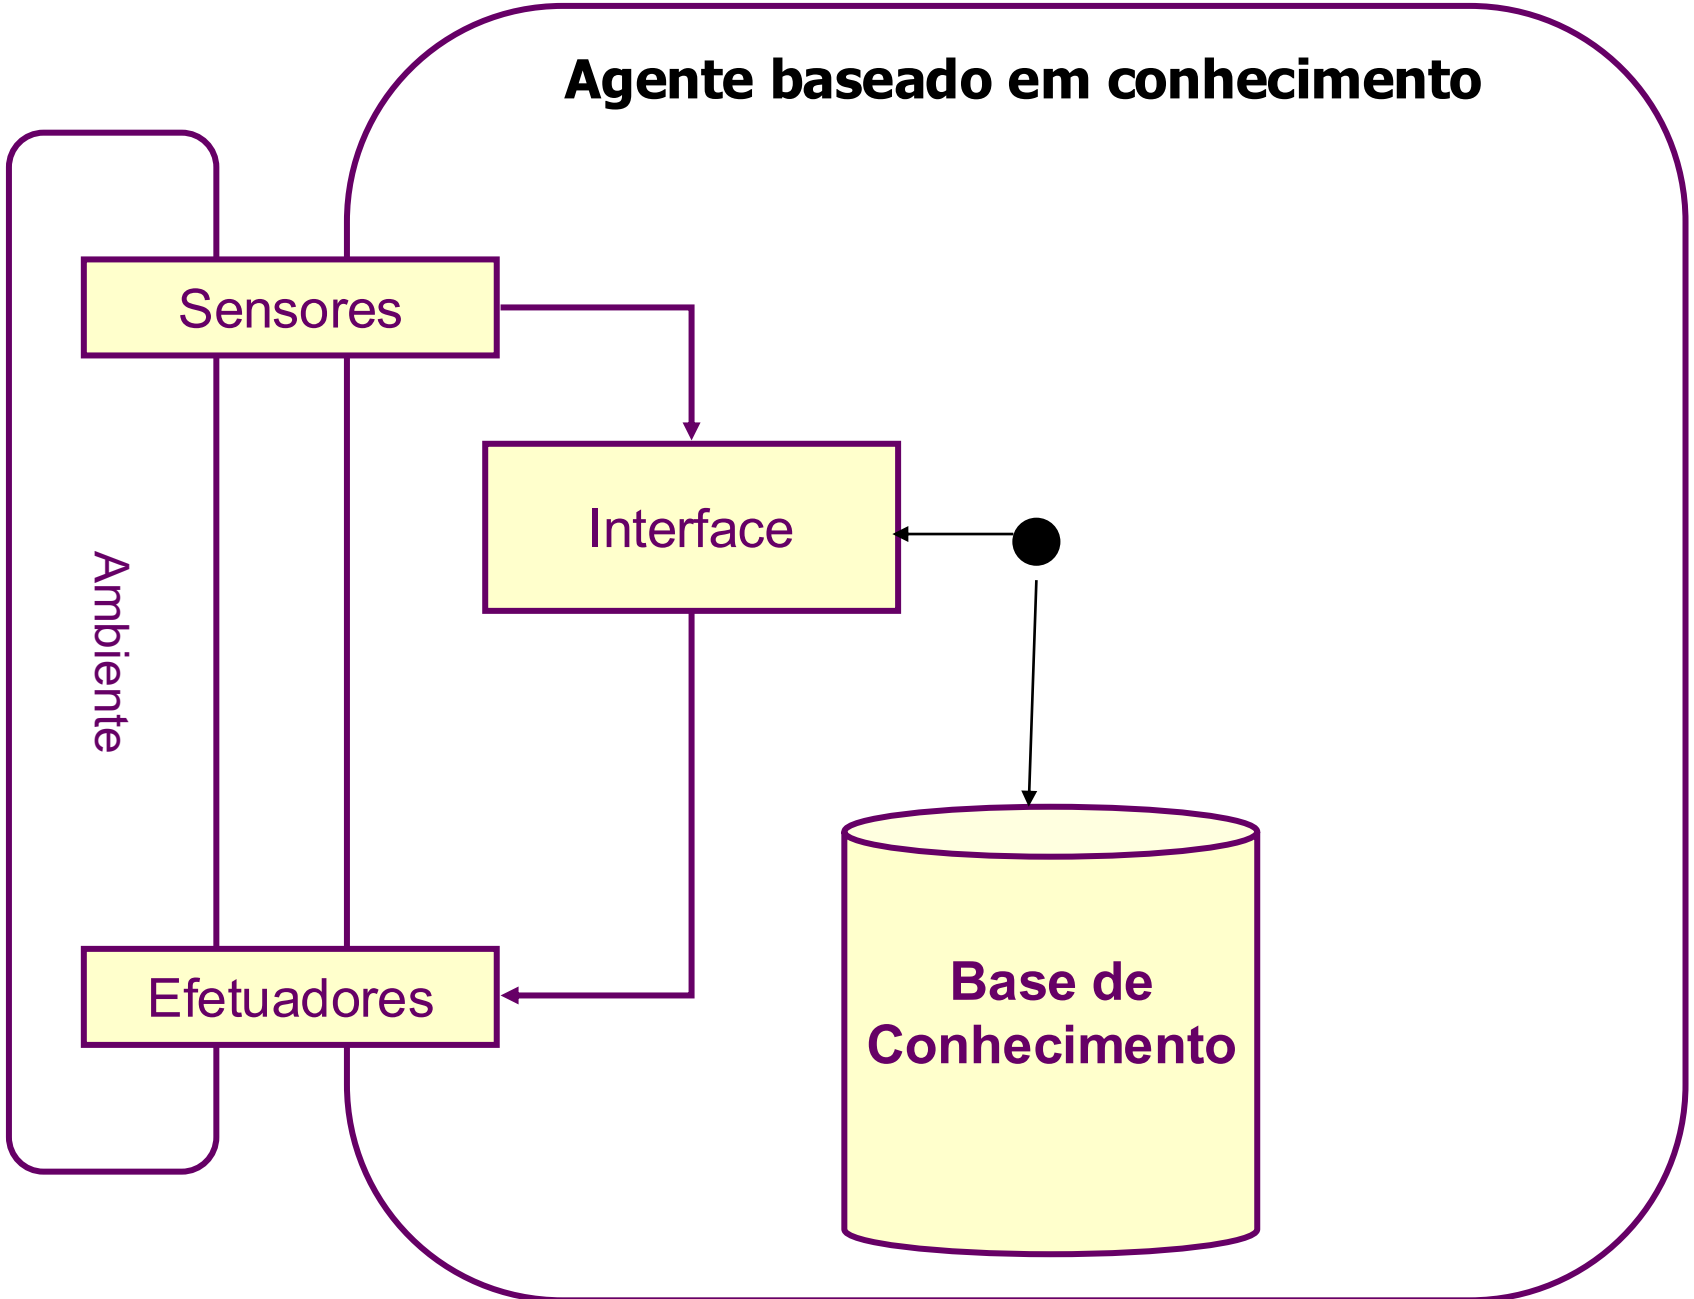
- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **4 atributos e 3 classes** (Baseado no livro do Luger: IA)

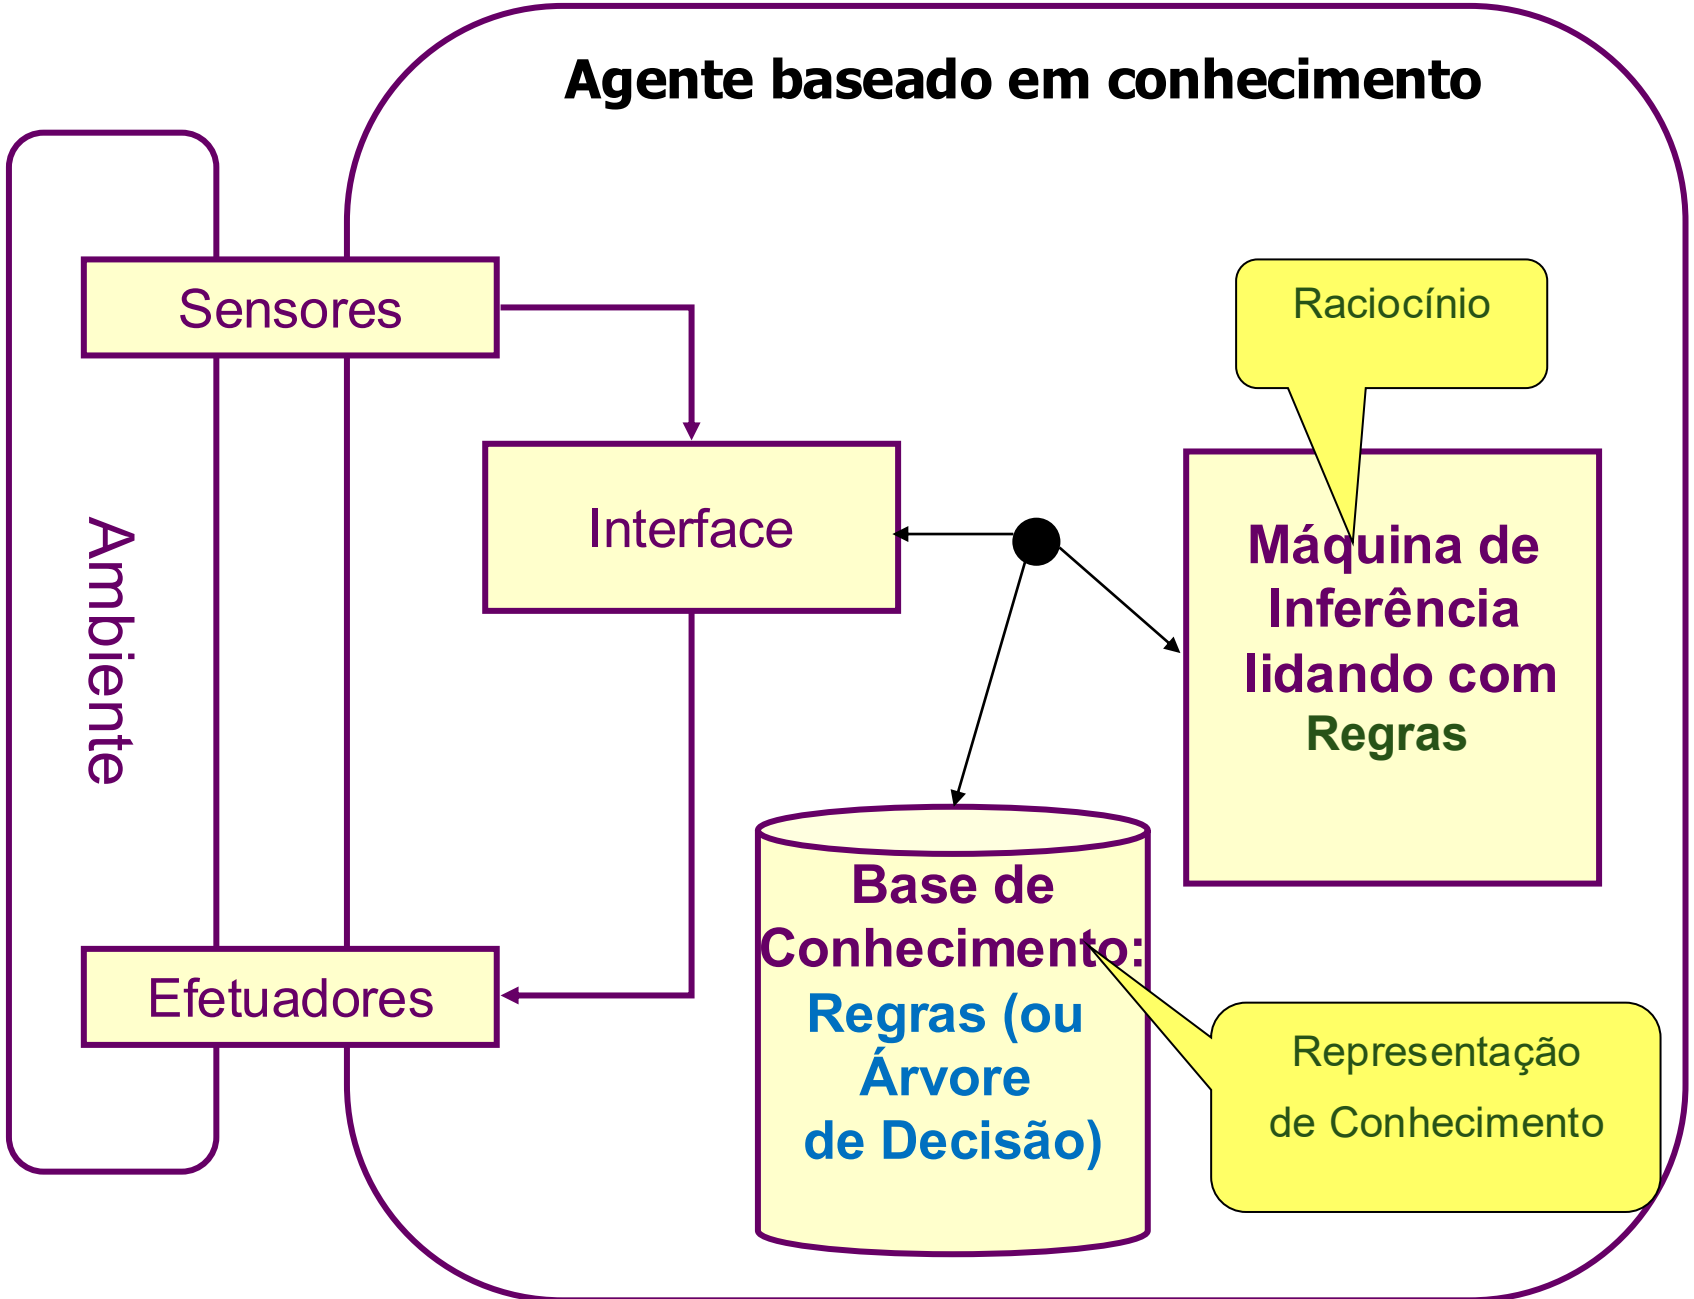
	Historia de Crédito	Dívida	Garantia	Renda	Risco
E1	Ruim	Alta	Nenhuma	$0 a $15k	Alto
E2	Desconhecida	Alta	Nenhuma	$15 a $35k	Alto
E3	Desconhecida	Baixa	Nenhuma	$15 a $35k	Moderado
E4	Desconhecida	Baixa	Nenhuma	$0 a $15k	Alto
E5	Desconhecida	Baixa	Nenhuma	Acima de $35k	Baixo
E6	Desconhecida	Baixa	Adequada	Acima de $35k	Baixo
E7	Ruim	Baixa	Nenhuma	$0 a $15k	Alto
E8	Ruim	Baixa	Adequada	Acima de $35k	Moderado
E9	Boa	Baixa	Nenhuma	Acima de $35k	Baixo
E10	Boa	Alta	Adequada	Acima de $35k	Baixo
E11	Boa	Alta	Nenhuma	$0 a $15k	Alto
E12	Boa	Alta	Nenhuma	$15 a $35k	Moderado
E13	Boa	Alta	Nenhuma	Acima de $35k	baixo
E14	Ruim	Alta	Nenhuma	$15 a $35k	Alto

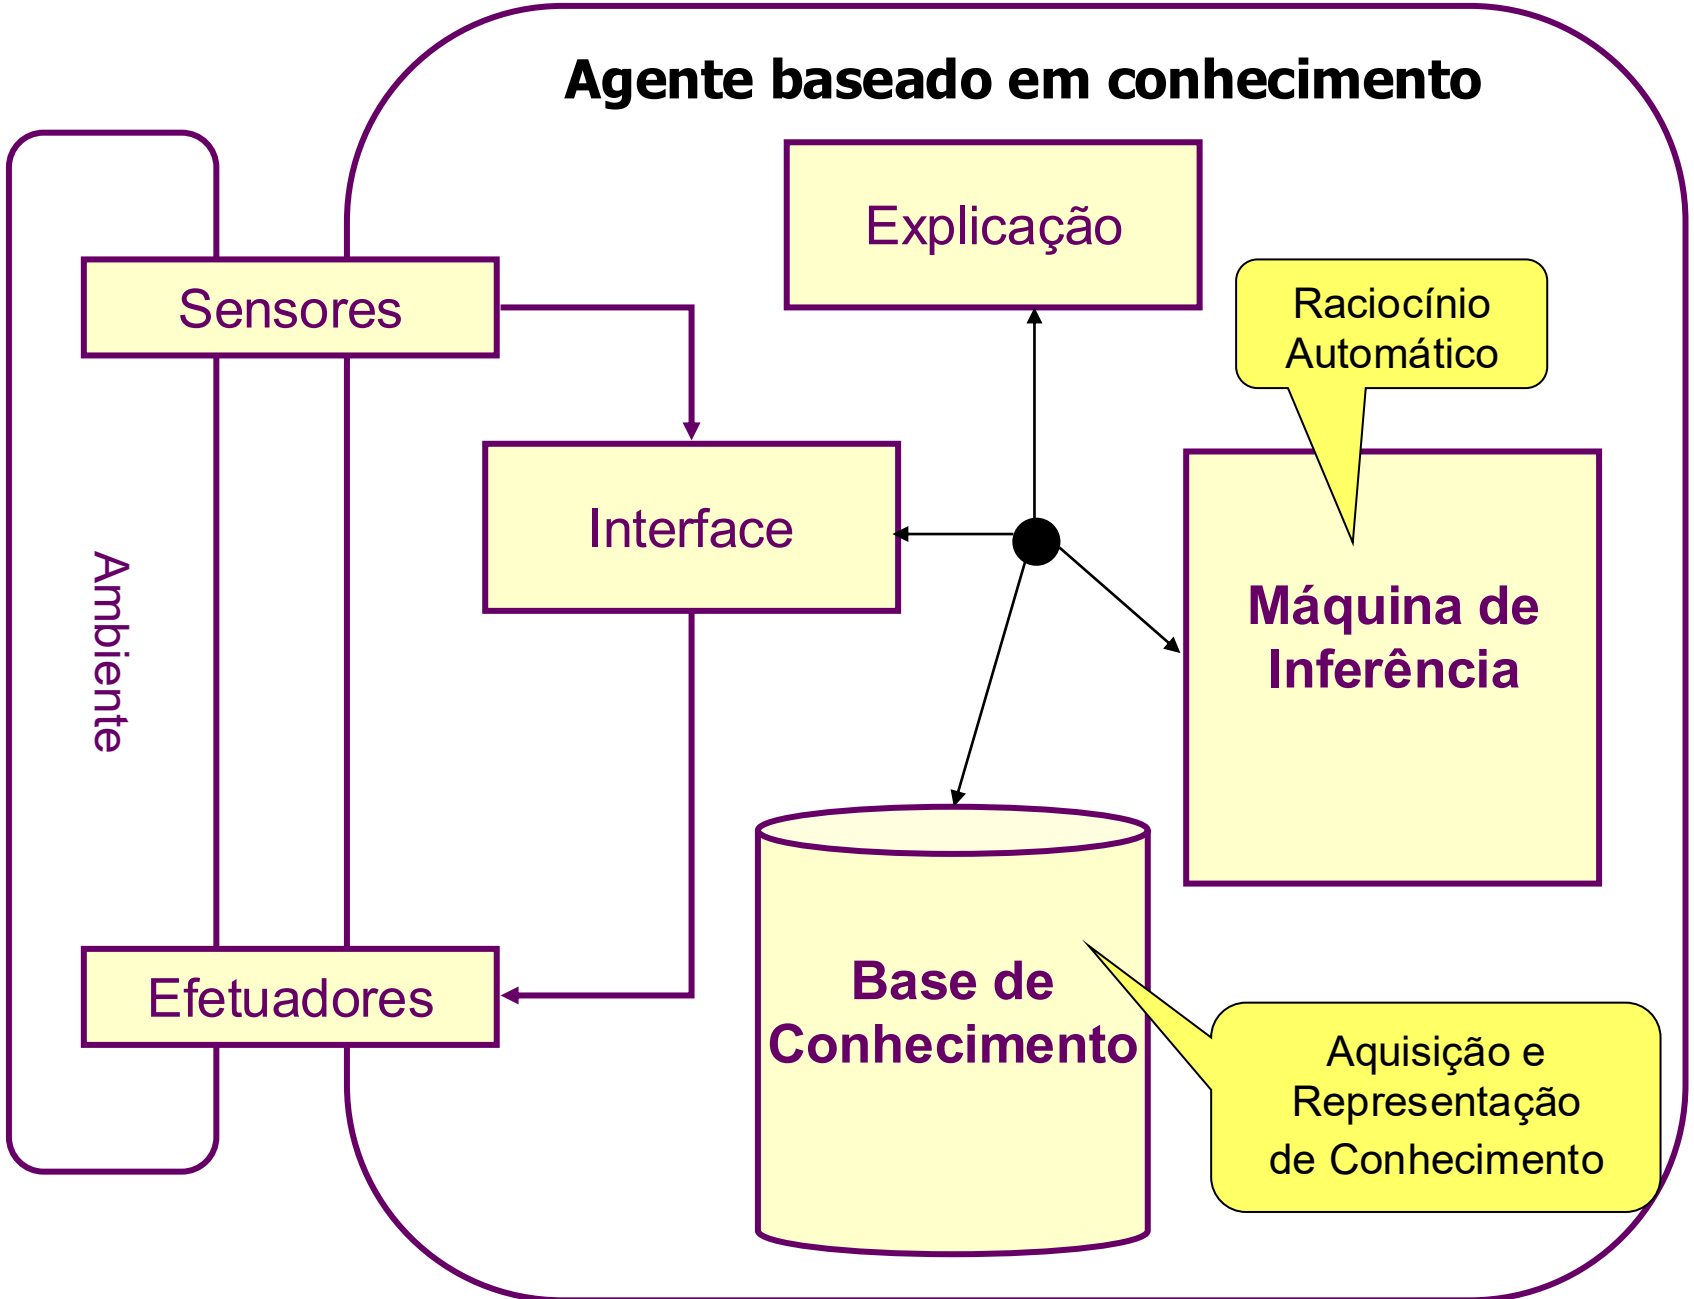
Árvore de Decisão

- **Ex**.: Avaliação de Risco de crédito




Agente baseado em conhecimento
Sensores
Interface
Ambiente
Efetuadores
Base de
Conhecimento


Agente baseado em conhecimento
Sensores
Ambiente
Interface
Raciocínio
Máquina de Inferência lidando com Regras
Base de Conhecimento: Regras (ou Árvore de Decisão)
Representação de Conhecimento
Efetuadores


Agente baseado em conhecimento
Explicação
Sensores
Raciocínio Automático
Interface
Máquina de Inferência
Ambiente
Base de Conhecimento
Efetuadores
Aquisição e Representação de Conhecimento

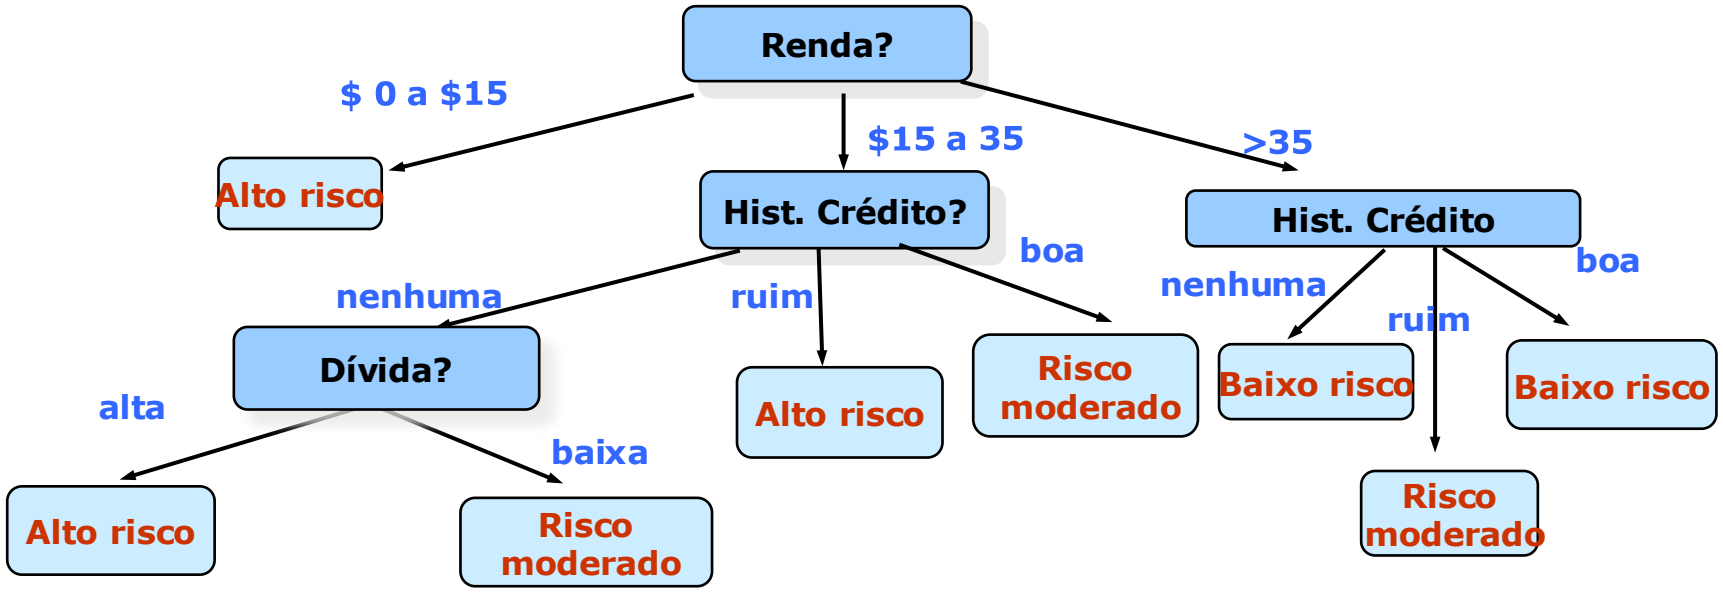
Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **4 atributos e 3 classes** (Baseado no livro do Luger: IA)

	Historia de Crédito	Dívida	Garantia	Renda	Risco
E1	Ruim	Alta	Nenhuma	$0 a $15k	Alto
E2	Desconhecida	Alta	Nenhuma	$15 a $35k	Alto
E3	Desconhecida	Baixa	Nenhuma	$15 a $35k	Moderado
E4	Desconhecida	Baixa	Nenhuma	$0 a $15k	Alto
E5	Desconhecida	Baixa	Nenhuma	Acima de $35k	Baixo
E6	Desconhecida	Baixa	Adequada	Acima de $35k	Baixo
E7	Ruim	Baixa	Nenhuma	$0 a $15k	Alto
E8	Ruim	Baixa	Adequada	Acima de $35k	Moderado
E9	Boa	Baixa	Nenhuma	Acima de $35k	Baixo
E10	Boa	Alta	Adequada	Acima de $35k	Baixo
E11	Boa	Alta	Nenhuma	$0 a $15k	Alto
E12	Boa	Alta	Nenhuma	$15 a $35k	Moderado
E13	Boa	Alta	Nenhuma	Acima de $35k	baixo
E14	Ruim	Alta	Nenhuma	$15 a $35k	Alto

Árvore de Decisão

- **Ex**.: Avaliação de Risco de crédito



Base de Conhecimento para o Problema do Gerente: Risco de Crédito

Se RENDA = 0 a 15K, então RISCO = ALTO
Se RENDA = 15k a 35k e CRÉDITO = RUIM, então RISCO = ALTO
Se RENDA = 15k a 35k e CRÉDITO = BOA, então RISCO = MODERADO
Se RENDA = 15K a 35k e CRÉDITO = DESCONHECIDO e DÍVIDA = ALTA, então RISCO = ALTO
Se RENDA = 15k a 35k e CRÉDITO = DESCONHECIDO e DÍVIDA = BAIXA, então RISCO = MODERADO
Se RENDA > 35k e CRÉDITO = RUIM, então RISCO = MODERADO
Se RENDA > 35k e CRÉDITO = DESCONHECIDO, então RISCO = BAIXO
Se RENDA > 35k e CRÉDITO = BOA, então RISCO = BAIXO

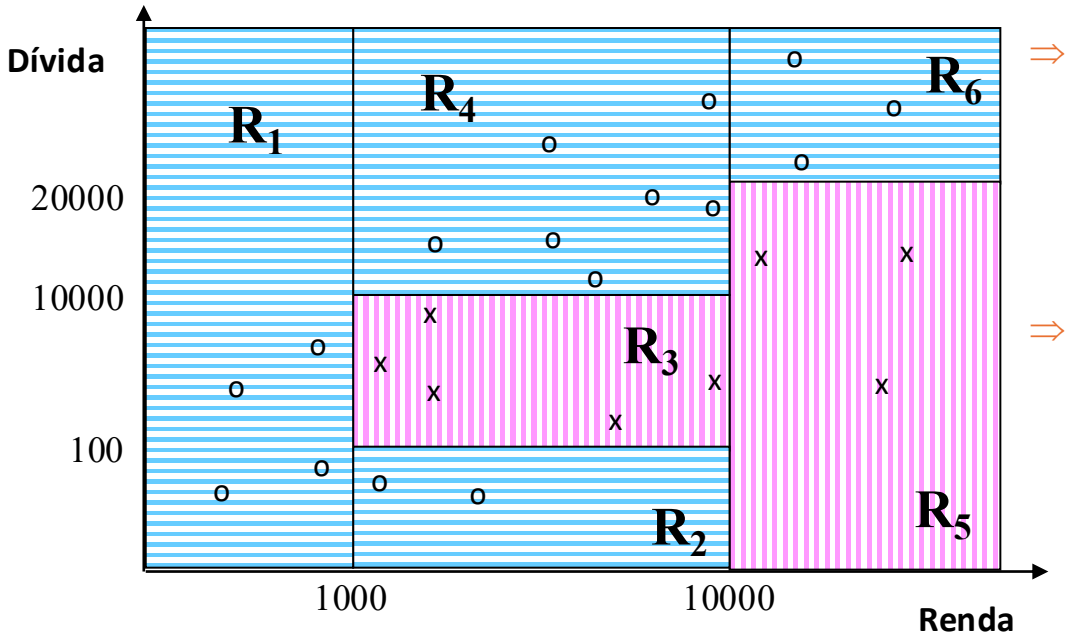
Como se constrói uma Árvore de Decisão?

Aprendizagem de Máquina Supervisionada

Indução de Árvore de Decisão

Indução de Árvore de Decisão: Particionamento

- **Ex.**: Utilização dos atributos ***renda*** e ***dívida*** de 23 clientes de um banco p/ classificá-los como lucrativos (L, x) ou então não lucrativos (NL, o)



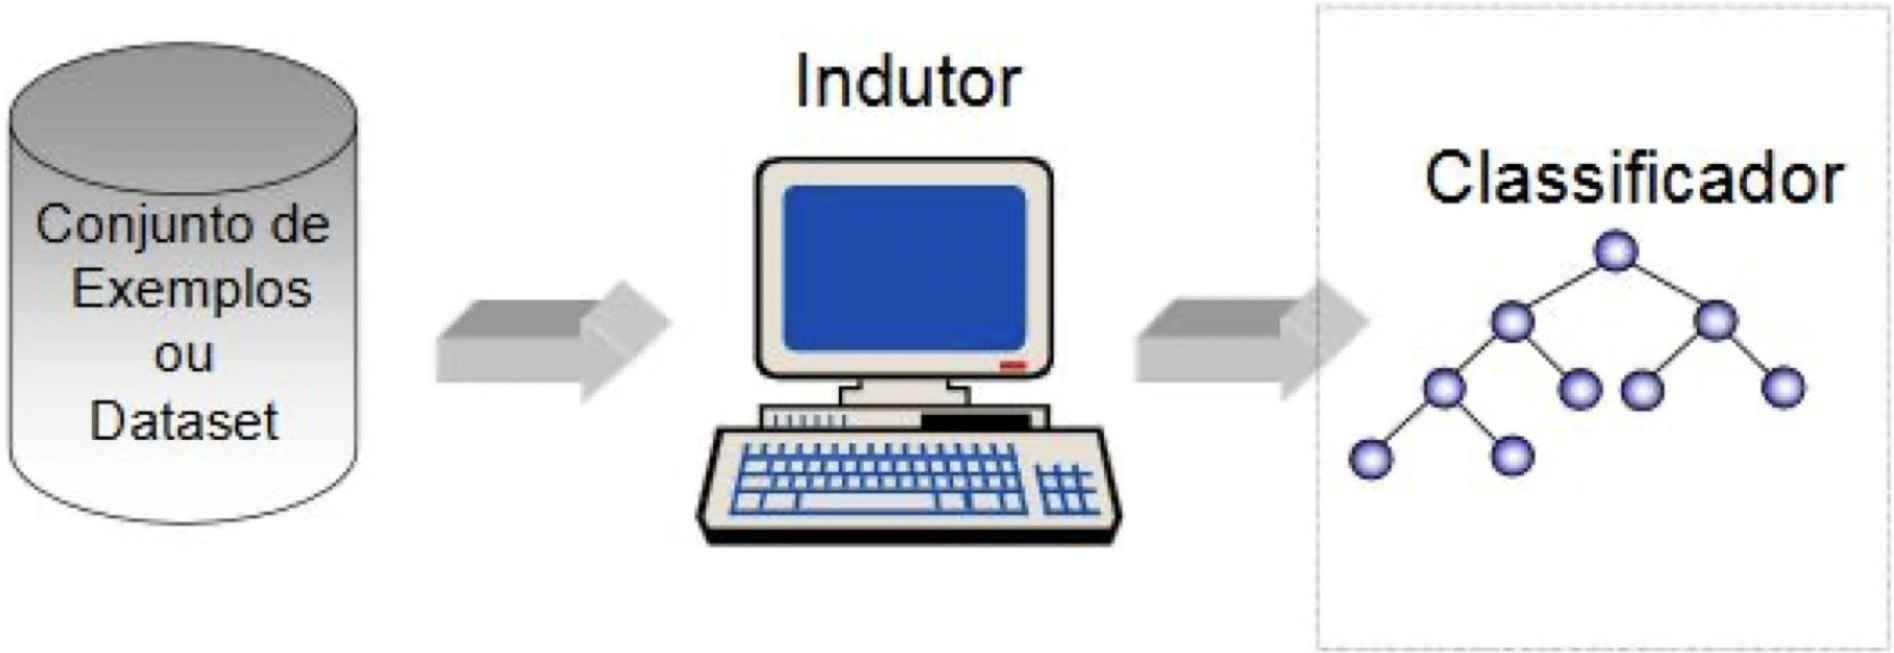
⇒ Neste caso, o diagrama de retângulos é a representação mais adequada para se visualizar a partição do espaço de características gerada pela árvore de decisão

⇒ Todos os pontos dentro de um retângulo são classificados da mesma forma, pois todos satisfazem a regra que define o retângulo

R_4: Se [illegible] Então L

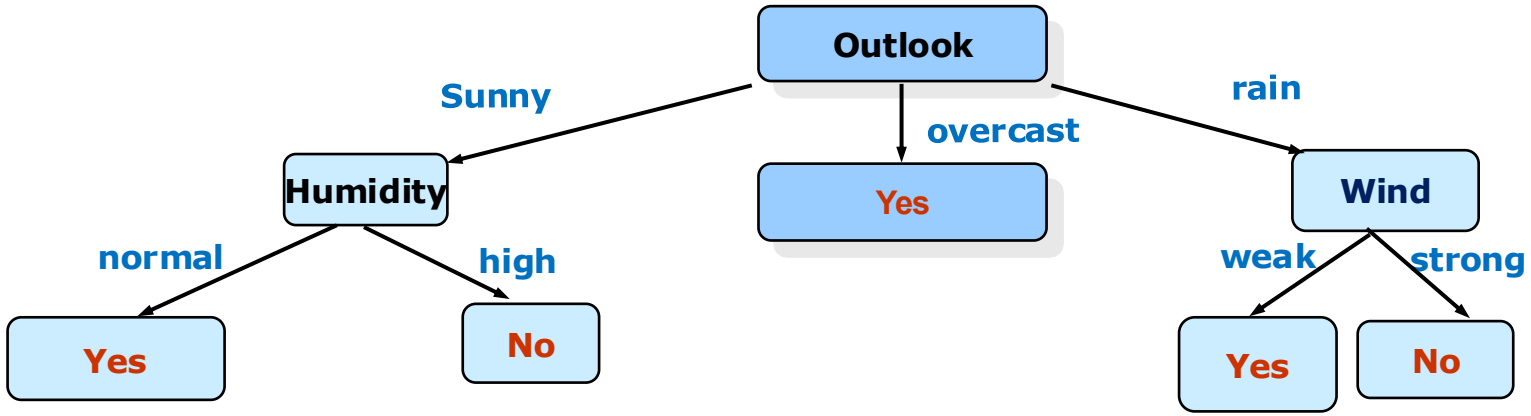
Classificador

Dado um conjunto de exemplos, o classificador é a saída do indutor.



Representação de uma Árvore de Decisão

- **Ex**.: Uma AD para o conceito PlayTennis nesse conjunto de dados



Árvore de Decisão

- **O que é uma AD?**

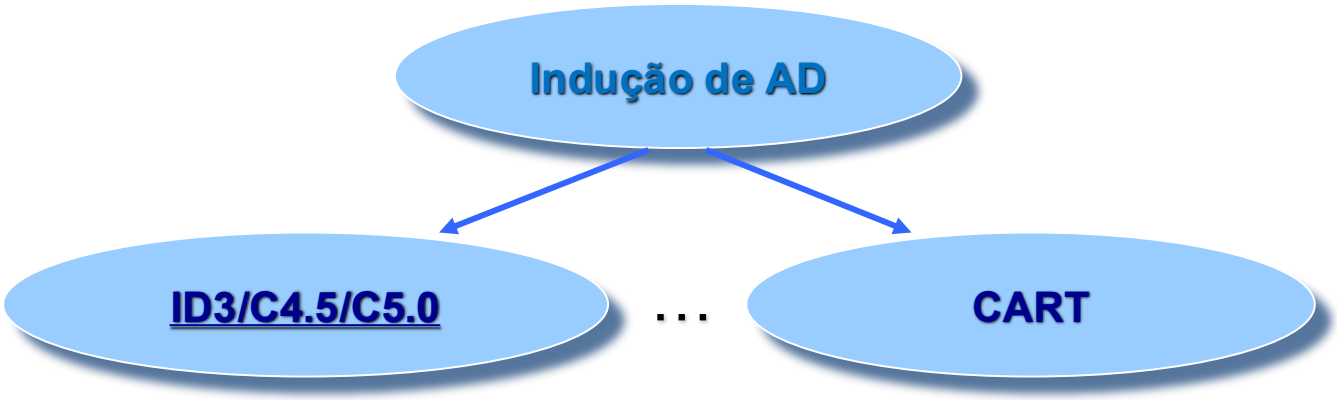
  - Uma AD é uma estrutura de dados (**Grafo acíclico direcionado,** no qual cada nó ou é um nó de divisão, ou um nó folha) definida recursivamente como:

    - Um **nó de divisão (decisão),** com 2 ou + sucessores que contém um teste sobre algum atributo
      - Para cada resultado do teste existe uma aresta para uma subárvore.
      - Cada subárvore tem a mesma estrutura que a árvore. ou
    - Um **nó folha** que corresponde a uma classe.

Construção
de uma
Árvore de Decisão

Algoritmos de Aprendizagem de AD

Indução de Árvore de Decisão



ID3 → C4.5 → C5.0

Aprendizagem de AD

- **Algoritmo ID3**
  - Iterative Dichotomizer (Quinlan 1986)
  - Algoritmo recursivo e baseado em busca gulosa, procurando, sobre um conjunto de atributos, aqueles que “melhor” dividem os exemplos, gerando sub-árvores.
  - Aprende uma AD por uma construção Top-down
    - Questão inicial: Qual atributo deveria ser testado na raiz da árvore?
      - Cada atributo é avaliado usando um teste estatístico para determinar quão bem ele sozinho classifica os exemplos do CT.
  - O ID3 utiliza as noções de entropia e ganho de informação para selecionar a melhor divisão.

Aprendizagem de AD

- **Iterative** Dichotomizer
  - **Algoritmo ID3 (Quinlan 1986)**

```
function APRENDIZAGEM_DA_ID3(exemplos,atributos,default) : árvore de decisão
    Se (exemplos é vazio)
    então return default
    senão if (todos os exemplos têm a mesma classificação)
          então return (a classificação)
          senão Se (atributos é vazio)
                então return maioria(exemplos)
                senão melhor <- ESCOLHA_MELHOR_ATRIBUTO(atributos,exemplos)
                      árvore <- nova árvore com raiz "melhor"
                      Para cada valor v_i de melhor faça
                        exemplos_i <- exemplos onde melhor = v_i
                        subárvore <- APRENDIZAGEM_DA_ID3(exemplos_i,
                                                         atributos-{melhor},
                                                         maioria(exemplos))
                        adicione subárvore como um ramo à árvore com rótulo v_i
                        return árvore;
```

Fase de Construção de uma AD

Particionar repetidamente os dados de treinamento até que todos os exemplos em cada partição pertençam a uma classe.

- Particionamento
- Critério para escolha de atributo raiz

Qual Atributo é o melhor classificador?

Qual atributo deve ser selecionado como o **mais informativo** para classificar os exemplos?

Articular as noções de Entropia e Ganho de Informação.

Há 2 passoa para calcular o ganho de informação para cada atributo

→ Calcular entropia do “target”.

→ Calcular a entropia de cada atributo.

Cálculo de **Entropia**
e
Ganho de Informação

Cálculo de **Entropia**

$$\text{Entropy} = -\sum_{i=1}^{n} p_i * \text{Log}_2(p_i)$$

Cálculo do **Ganho de informação**

Ganho de Informação: Decréscimo de Entropia, com a **Partição** de S

Ganho de informação de um **atributo *A*** em relação a um conjunto *S*:

$$\mathbf{GI}(S, A) = E(S) - \sum_{v \in \mathbf{Valores}(A)} \frac{|S_v|}{|S|} E(S_v)$$

Onde:

v: valores possíveis para *A*

S_v: Subconjunto de *S* em que o valor de *A* é igual a *v*

|*S*|: *nº de elementos de S*

Qual Atributo é o melhor classificador?

Qual atributo deve ser selecionado como o **mais informativo** para classificar os exemplos?

Articular as noções de Entropia e Ganho de Informação.

Há 2 passos para calcular o ganho de informação para cada atributo

→ Calcular entropia do “target”.

→ Calcular a entropia de cada atributo.

Cálculo de Entropia
e
Ganho de Informação

Cálculo de **Entropia**

$$\text{Entropy} = -\sum_{i=1}^{n} p_i * \text{Log}_2(p_i)$$

Cálculo do Ganho de informação

Ganho de Informação: Decréscimo de Entropia, com a **Partição** de S

Ganho de informação de um **atributo *A*** em relação a um conjunto *S*:

$$\mathbf{GI}(S, A) = E(S) - \sum_{v \in \mathbf{Valores}(A)} \frac{|S_v|}{|S|} E(S_v)$$

Onde:

v: valores possíveis para *A*

S_v: Subconjunto de *S* em que o valor de *A* é igual a *v*

|*S*|: *nº de elementos de S*

Indução de Árvore de Decisão

Exemplo de **Construção de uma Árvore de Decisão** para o conjunto de dados a seguir

Vamos iniciar o entendimento da construção da AD, usando uma outra base de dados (PlayTennis), depois voltaremos para base do Risco

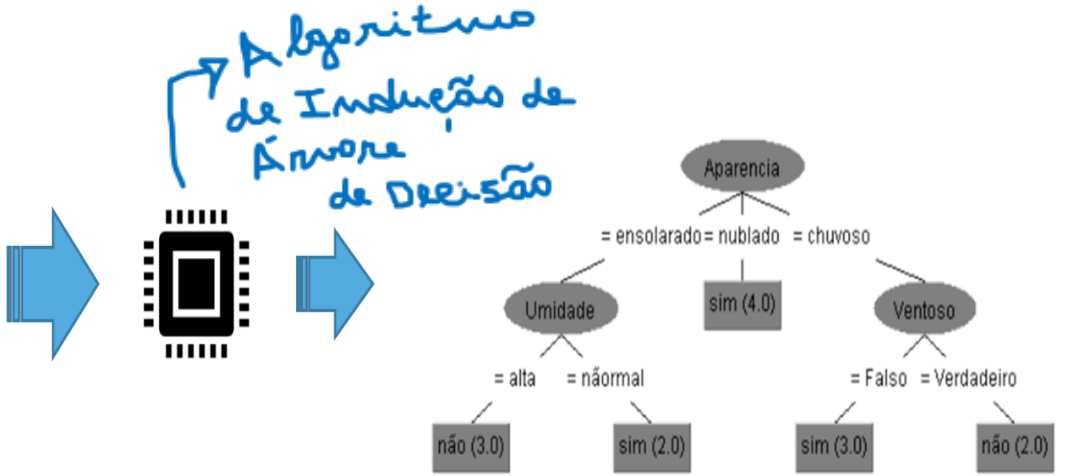
Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos (treinamento) sobre Jogar Tenis:**
  - **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Como a Máquina Aprende?

Aparencia	Temperatura	Umidade	Ventoso	Jogar
ensolarado	quente	alta	FALSO	não
ensolarado	quente	alta	VERDADEIRO	não
nublado	quente	alta	FALSO	sim
chuvoso	amena	alta	FALSO	sim
chuvoso	frio	normal	FALSO	sim
chuvoso	frio	normal	VERDADEIRO	não
nublado	frio	normal	VERDADEIRO	sim
ensolarado	amena	alta	FALSO	não
ensolarado	frio	normal	FALSO	sim
chuvoso	amena	normal	FALSO	sim
ensolarado	amena	normal	VERDADEIRO	sim
nublado	amena	alta	VERDADEIRO	sim
nublado	quente	normal	FALSO	sim
chuvoso	amena	alta	VERDADEIRO	não



Dados

Algoritmo + Processamento

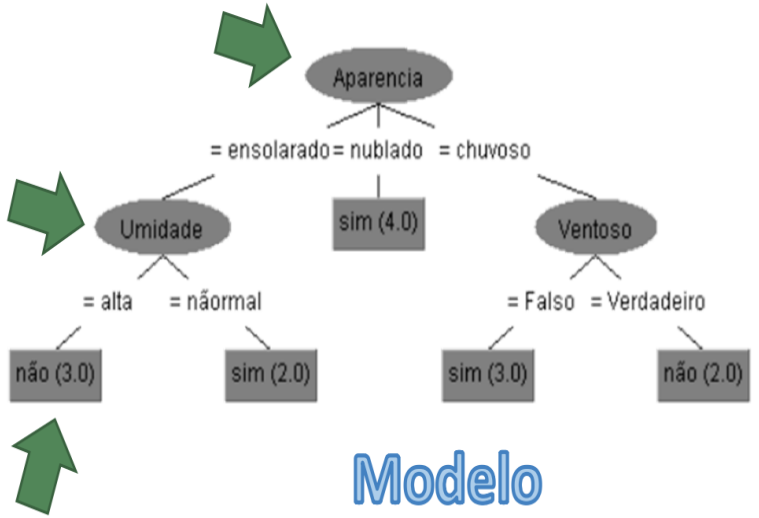
Modelo



Nova Informação : Testando o Modelo

Aparencia	Temperatura	Umidade	Ventoso	Jogar
ensolarado	quente	alta	FALSO	não

Nova Informação



Modelo



Exemplo de **Construção de uma Árvore de Decisão (Base de Conhecimento)** para o conjunto de dados a seguir

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos (treinamento) sobre Jogar Tenis:**
  - **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Entropia da Classe para a Coleção de Exemplos: **E**(S)

- ***A Entropia de S relativa a essa classificação booleana é dada por:***

$$\text{Entropy} = -\sum_{i=1}^{n} p_i * \text{Log}_2(p_i)$$

Entropia(S) = Entropia (PlayTennis) = Entropia $[9_{yes}, 5_{no}]$

Obs.: Lembrar de falar da base do log que é 2, mas se mudasse para 10, por exemplo, não afetaria o resultado do que pretendemos, que é ranquear.

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos sobre Jogar Tenis:**
- **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

Day	PlayTennis
D1	No
D2	No
D3	Yes
D4	Yes
D5	Yes
D6	No
D7	Yes
D8	No
D9	Yes
D10	Yes
D11	Yes
D12	Yes
D13	Yes
D14	No

- *A Entropia de S relativa a essa classificação booleana é dada por*

$$Entropy = -\sum_{i=1}^{n} p_i * Log_2(p_i)$$

Primeiramente, calculamos a entropia do target (PlayTennis), **vendo como tá o nível de mistura (embaralhamento) entre Yes e No**, como a seguir. Lembrar do exemplo da Figura.

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos sobre Jogar Tenis:**
- **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

Day	PlayTennis
D1	No
D2	No
D3	Yes
D4	Yes
D5	Yes
D6	No
D7	Yes
D8	No
D9	Yes
D10	Yes
D11	Yes
D12	Yes
D13	Yes
D14	No

Entropia(S) = Entropia (PlayTennis) = Entropia $[9_{yes}, 5_{no}]$

Entropia(PlayTennis) $= -(9/14) \times \log_2(9/14) - (5/14) \log_2(5/14) = 0.940$

Yes = 9/14 , No = 5/14

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos sobre Jogar Tenis:**
- **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

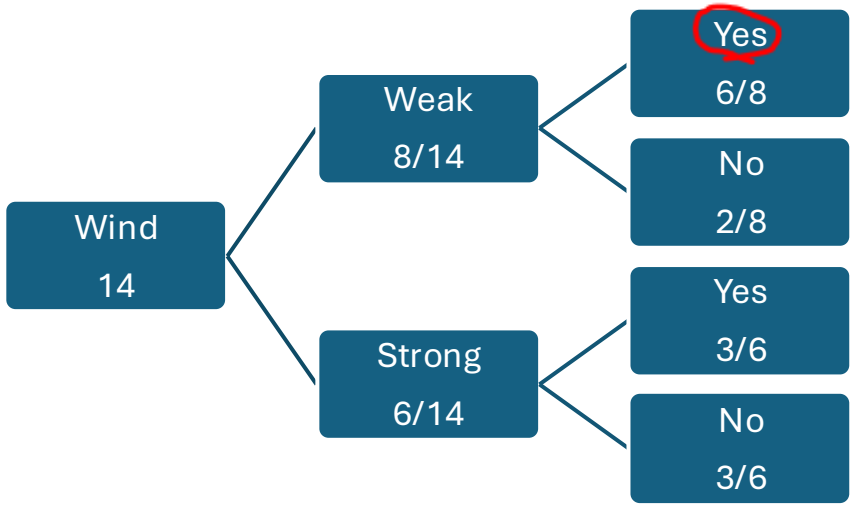
Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Ganho de Informação: Cálculo de $info_x(S)$

Ganho de Informação com o atributo Wind

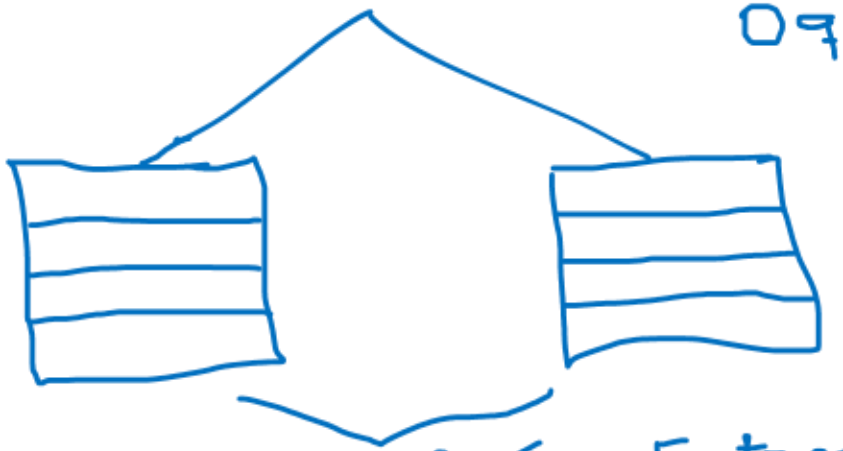
Wind

Wind	PlayTennis
Weak	No
Strong	No
Weak	Yes
Weak	Yes
Weak	Yes
Strong	No
Strong	Yes
Weak	No
Weak	Yes
Weak	Yes
Strong	Yes
Strong	Yes
Weak	Yes
Strong	No



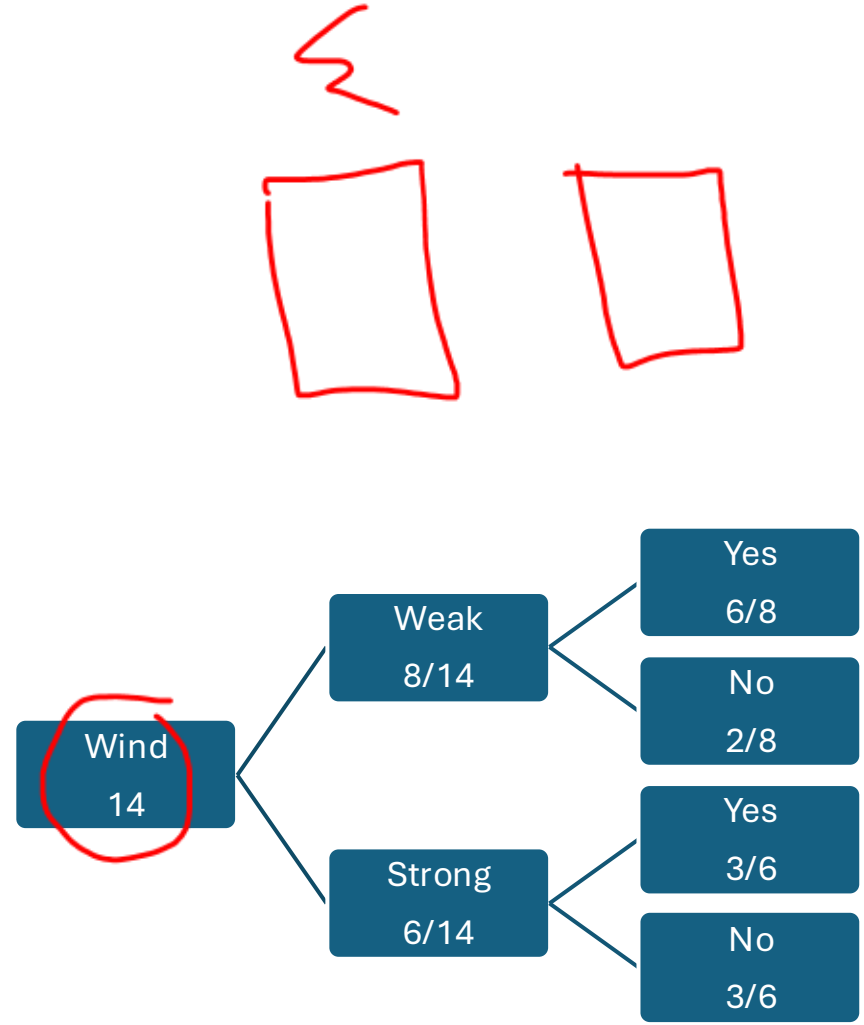
Ganho de Informação: Cálculo de $info_x(S)$

Ganho de Informação com o atributo Wind



Wind

Wind	PlayTennis
Weak	No
Strong	No
Weak	Yes
Weak	Yes
Weak	Yes
Strong	No
Strong	Yes
Weak	No
Weak	Yes
Weak	Yes
Strong	Yes
Strong	Yes
Weak	Yes
Strong	No



Wind + **weak**

Wind	PlayTennis
Weak	No
Weak	Yes
Weak	Yes
Weak	Yes
Weak	No
Weak	Yes
Weak	Yes
Weak	Yes

$$\sum -p_i \log_2 p_i$$



Wind = Weak (8/14), tendo $S_{weak} \leftarrow [6_{yes}, 2_{no}]$
ou seja,

6/8 PlayTennis = yes, e 2/8 PlayTennis = no

Entropia(S_{weak}) = -(6/8) $\mathbf{log_2}$(6/8) – (2/8) $\mathbf{log_2}$(2/8)
= 0,811

Wind + **Strong**

Wind	PlayTennis
Strong	No
Strong	No
Strong	Yes
Strong	Yes
Strong	Yes
Strong	No



Wind = Strong (6/14), tendo $S_{strong} \leftarrow [3_{yes}, 3_{no}]$ ou seja,

3/6 PlayTennis = Yes e 3/6 PlayTennis = No

Entropia (S_{strong}) = -(3/6) $\mathbf{log_2}$(3/6) – (3/6) $\mathbf{log_2}$(3/6)
= 1,00

Ganho de Informação: Cálculo de $info_x(S)$

- AD: **Entropia da Partição segundo o atributo Wind**
- Entropia para Wind = Weak e para Wind = Strong

Entropia(S_{weak}) = -(6/8) $\mathbf{log_2}$(6/8) – (2/8) $\mathbf{log_2}$(2/8) = 0,811

Entropia (S_{strong}) = -(3/6) $\mathbf{log_2}$(3/6) – (3/6) $\mathbf{log_2}$(3/6) = 1,00

Portanto,

$$\mathbf{GI}(S, A) = E(S) - \sum_{v \in \mathbf{Valores}(A)} \frac{S_v}{S} E(S_v)$$

Ganho(S, Wind) = Entropia (S) - $\sum$ ($|S_v|/|S|$) Entropia (S_v)

$v \in \{Weak, Strong\}$

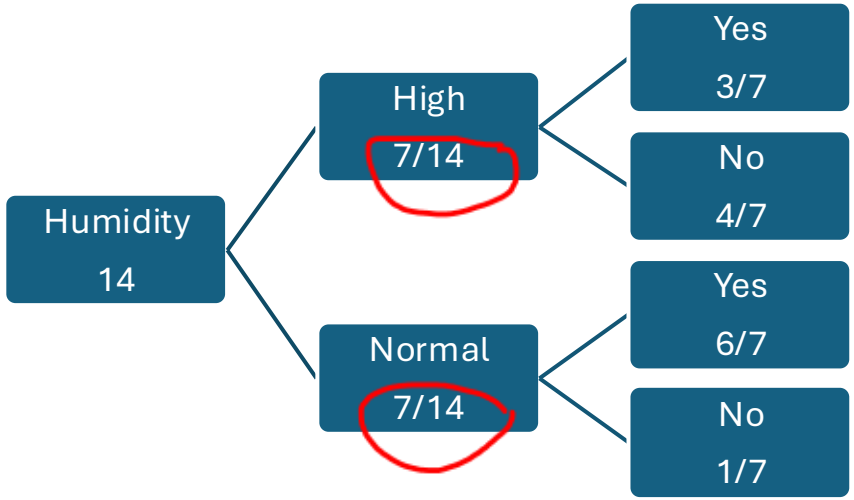
Ganho(S, Wind) = 0,940 – (8/14) x Entropia(S_{weak}) - (6/14) x Entropia(S_{strong})

Ganho(S, Wind) = 0,940 – (8/14) x 0,811 - (6/14) x 1,00 = 0,048

Ganho de Informação com o atributo Humidity

Humidity

Humidity	PlayTennis
High	No
High	No
High	Yes
High	Yes
Normal	Yes
Normal	No
Normal	Yes
High	No
Normal	Yes
Normal	Yes
Normal	Yes
High	Yes
Normal	Yes
High	No



Humidity + High

Humidity	PlayTennis
High	No
High	No
High	Yes
High	Yes
High	No
High	Yes
High	No



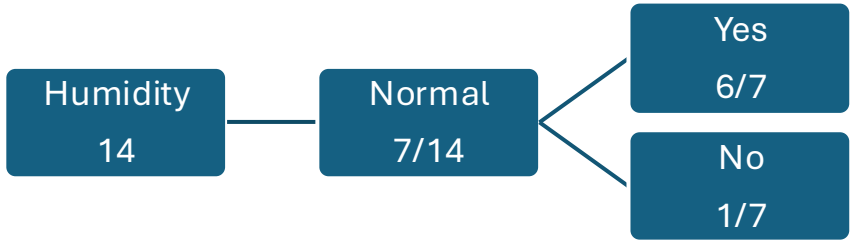
Humidity = High (7/14), tendo $S_{high} \leftarrow [3_{yes}, 4_{no}]$
ou seja,

3/7 PlayTennis = Yes, e 4/7 PlayTennis = No

Entropia(S) = -(3/7) $\mathbf{log_2}$(3/7) – (4/7) $\mathbf{log_2}$(4/7) = 0,985

Humidity + **Normal**

Humidity	PlayTennis
Normal	Yes
Normal	No
Normal	Yes
Normal	Yes
Normal	Yes
Normal	Yes
Normal	Yes



Humidity = **Normal (7/14)**, tendo
$S_{normal} \leftarrow [6_{yes}, 1_{no}]$ ou seja,

6/7 PlayTennis = Yes, e 1/7 PlayTennis = No

Entropia(S) = -(6/7) $\mathbf{log_2}$(6/7) – (1/7) $\mathbf{log_2}$(1/7) = 0,592

Ganho de Informação: Cálculo de $info_x(S)$

- AD: **Entropia da Partição segundo o atributo Humidity**
- Entropia para Humidity = High e para Humidity = Normal

$Entropia(S_{high}) = -(3/7)\ \mathbf{log_2}(3/7) - (4/7)\ \mathbf{log_2}(4/7) = 0{,}985$

$Entropia\ (S_{normal}) = -(6/7)\ \mathbf{log_2}(6/7) - (1/7)\ \mathbf{log_2}(1/7) = 0{,}592$

Portanto,

$$Ganho(S, Humidity) = Entropia\ (S) - \sum_{v \in Valores(A)} (|S_v|/|S|)\ Entropia\ (S_v)$$

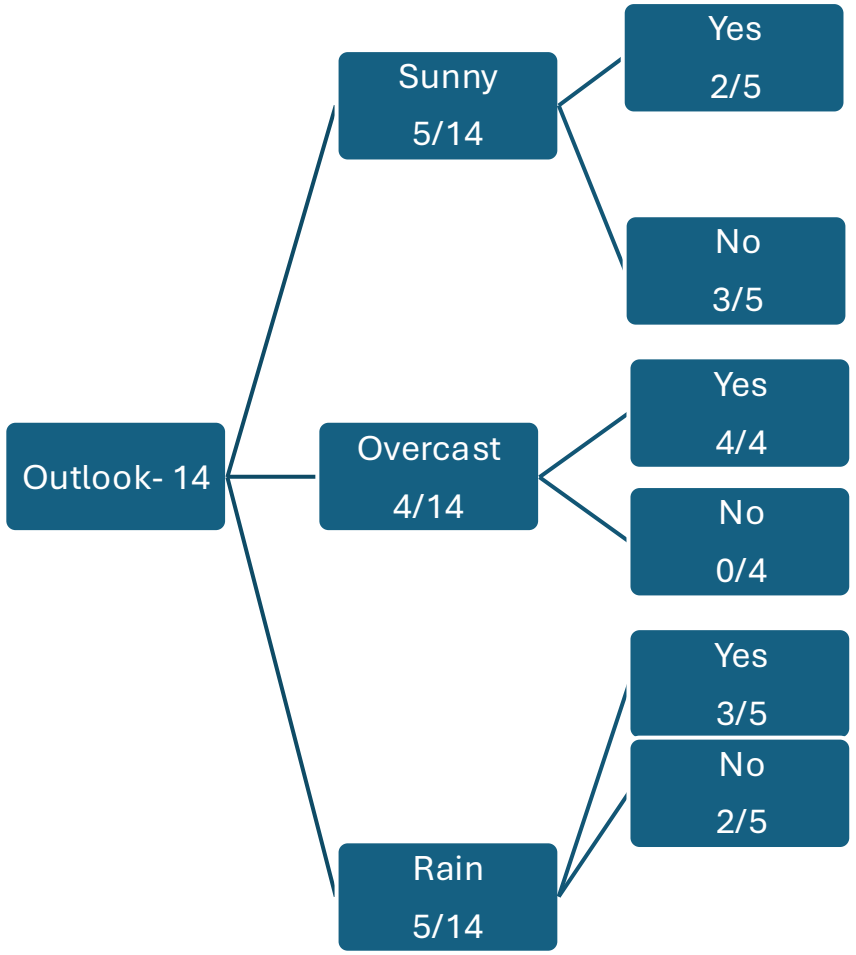
$Ganho(S, Humidity) = 0{,}940 - (7/14) \times Entropia(S_{high}) - (7/14) \times Entropia(S_{normal})$

$Ganho(S, Humidity) = 0{,}940 - (7/14) \times 0{,}985 - (7/14) \times 0{,}592 = 0{,}151$

Ganho de Informação com o atributo Outlook

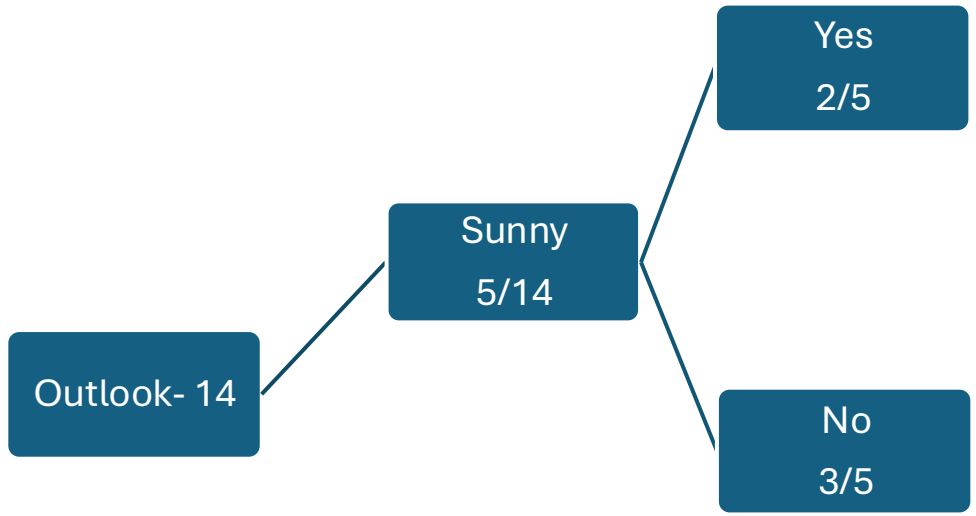
Outlook

Outlook	PlayTennis
Sunny	No
Sunny	No
Overcast	Yes
Rain	Yes
Rain	Yes
Rain	No
Overcast	Yes
Sunny	No
Sunny	Yes
Rain	Yes
Sunny	Yes
Overcast	Yes
Overcast	Yes
Rain	No



Outlook + Sunny

Outlook	PlayTennis
Sunny	No
Sunny	No
Sunny	No
Sunny	Yes
Sunny	Yes



Entropia (Ssunny) = 0,971

Ganho de informação com atributo = Outlook

Ganho(S, Outlook) = Entropia (S) - $\sum$ ($|S_v|/|S|$) Entropia (S_v)

Ganho(S, Outlook) = 0,940 – (5/14) x Entropia(S_{sunny}) - (4/14) x Entropia($S_{overcastl}$) - (5/14) x Entropia(S_{rainy})

Ganho(S, Outlook) = 0,940 – (5/14) x 0,971 - (4/14) x 0,0 - (5/14) x 0,971

Ganho(S, Outlook) = 0,940 – 0,693 = 0,247

Indução de Árvore de Decisão

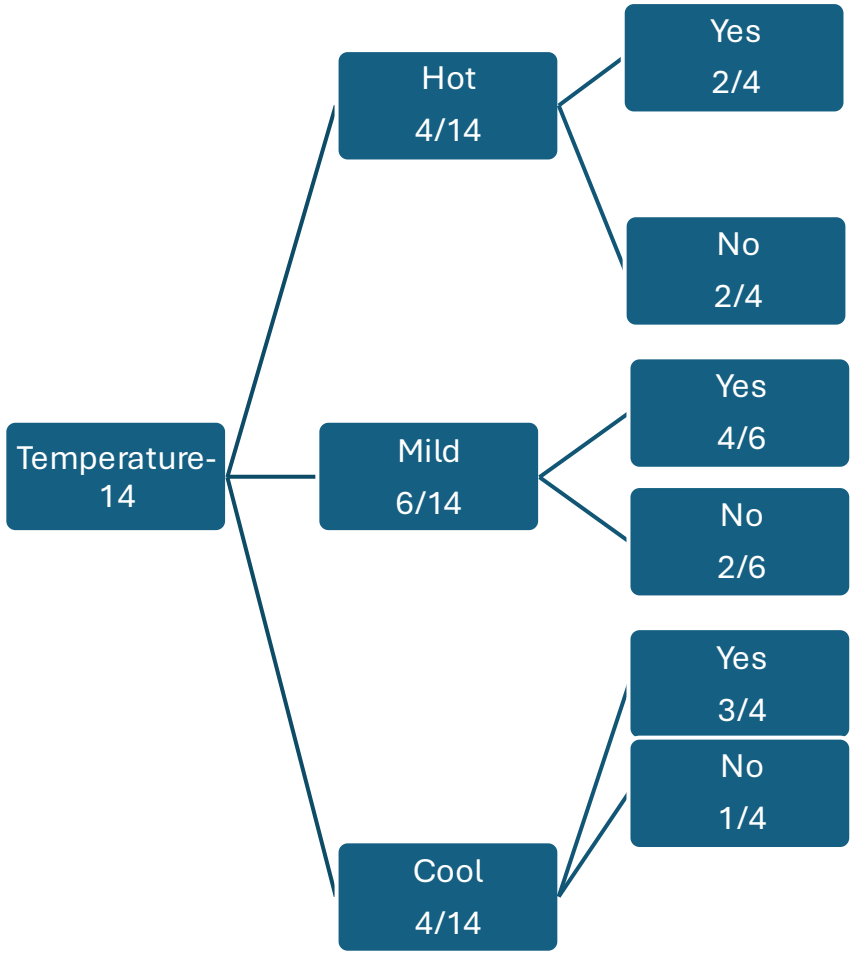
- **Ex.: Conjunto de Exemplos sobre Jogar Tenis:**
- **4 atributos e 2 classes** (Baseado no livro do Tom Mitchell)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Ganho de Informação com o atributo Temperature

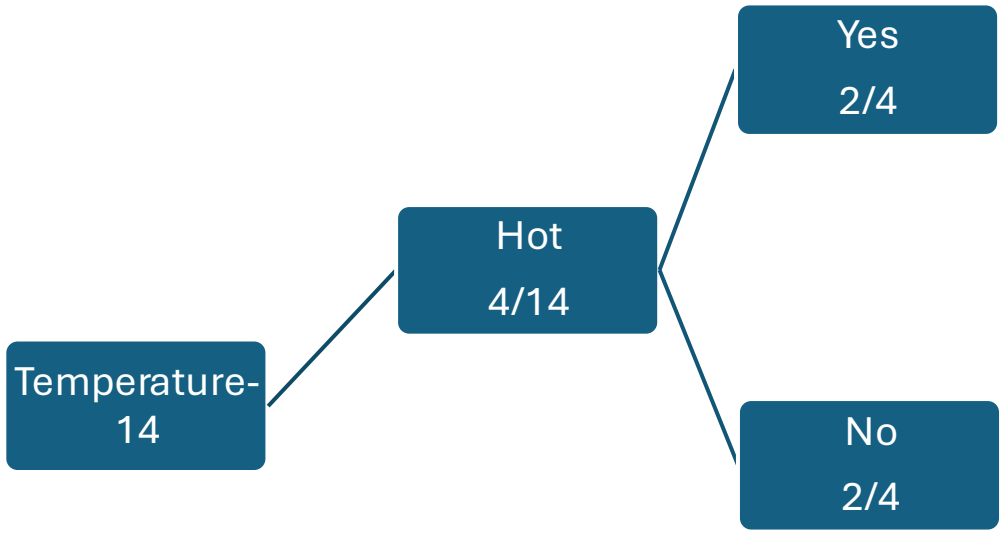
Temperature

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Temperature + Hot

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Entropia(S_{hot}) = -(2/4)log(2/4) – (2/4)log(2/4) = 1

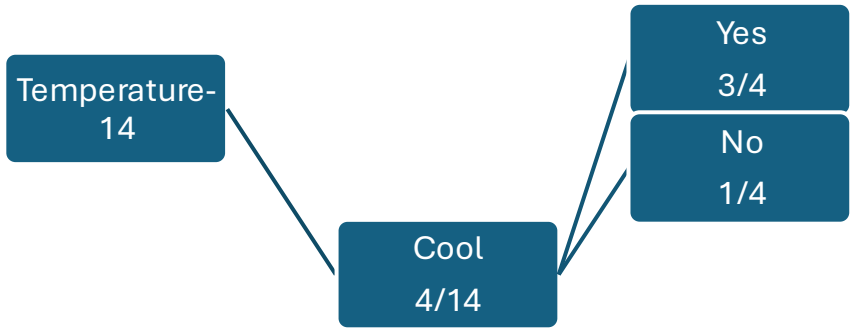
Temperature + Mild

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Temperature + Cool

Temperature	PlayTennis
Hot	No
Hot	No
Hot	Yes
Mild	Yes
Cool	Yes
Cool	No
Cool	Yes
Mild	No
Cool	Yes
Mild	Yes
Mild	Yes
Mild	Yes
Hot	Yes
Mild	No



Ganho de informação com atributo = Temperature

Ganho(S, Temperature) = Entropia (S) - ∑ ($|S_v|/|S|$) Entropia (S_v)

Ganho(S, Temperature) = 0,940 – (4/14) x Entropia(S_{hot}) - (6/14) x Entropia(S_{mild}) - (4/14) x Entropia(S_{cool})

Ganho(S, Temperature) = 0,940 – (4/14) x ?? - (6/14) x ?? - (4/14) x ??

Ganho(S, Temperature) = 0,940 – ?? = ??

Cálculo do Ganho de Informação em PlayTennis

- Ganho de informação para todos os 4 atributos são:

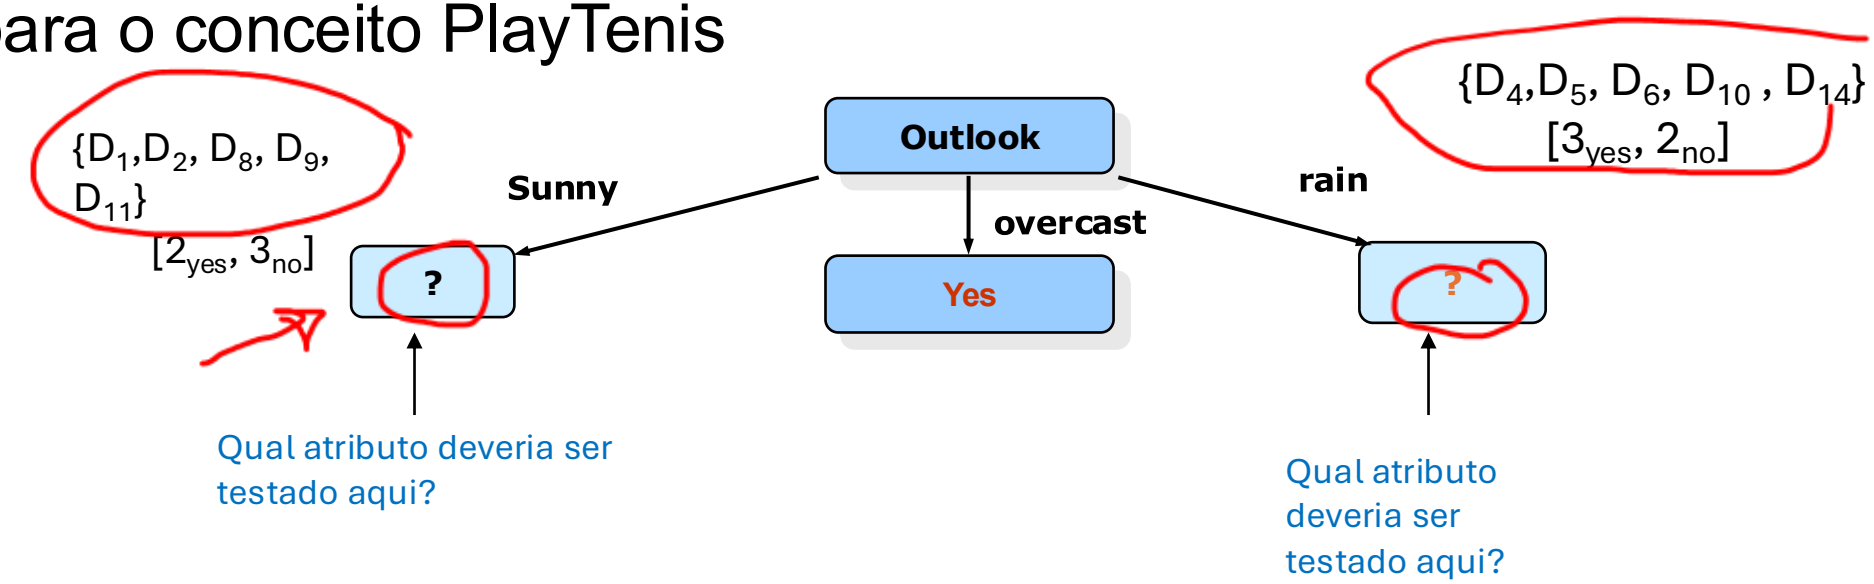
$$Ganho(S, Outlook) = 0.246$$
$$Ganho(S, Humidity) = 0.151$$
$$Ganho(S, Wind) = 0.048$$
$$Ganho(S, temperature) = 0.029$$

onde S denota a coleção de exemplos de treinamento da tabela dada.

Portanto, Outlook fornece o maior ganho de informação e assim será raiz da árvore, i.e., Outlook provê a melhor predição do atributo alvo.

Representação de uma Árvore de Decisão para PlayTennis

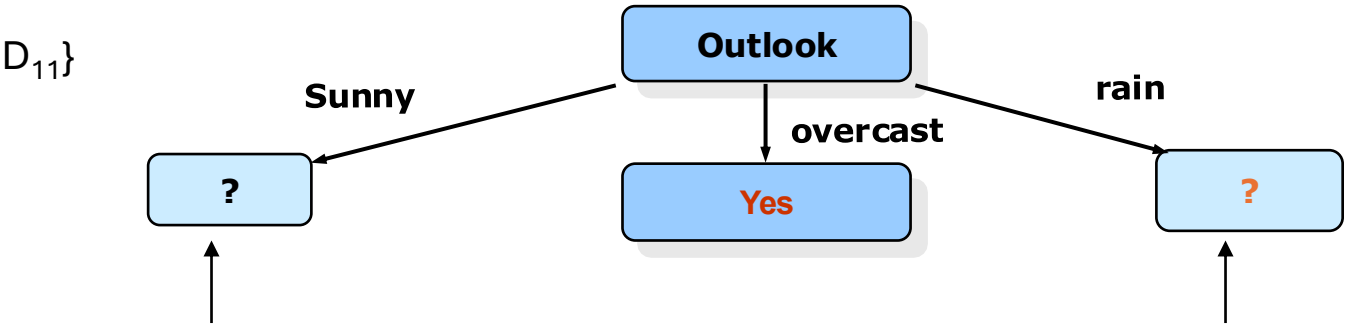
- **Ex**.: Uma AD para o conceito PlayTenis



Representação de uma Árvore de Decisão

- **Ex**.: A DT for the concept PlayTenis

$\{D_1, D_2, D_8, D_9, D_{11}\}$
$[2_{yes}, 3_{no}]$



Humidity

$S_{sunny} = \{D_1, D_2, D_8, D_9, D_{11}\}$

Ganho(S_{sunny}, Humidity) = 0,970 – (3/5). 0,0 – (2/5) . 0,0 = **0,970**
Ganho(S_{sunny}, Temperature) = 0,970 – (2/5). 0,0 – (2/5) . 1,0– (1/5). 0,0 = **0,570**
Ganho(S_{sunny}, Wind) = 0,970 – (2/5). 1,0 – (3/5) . 0,918 = **0,019**

Portanto, Humidity vai ser selecionado, pois é o atributo que apresenta maior ganho de informação

Cálculo do Ganho de Informação em PlayTennis

- Ganho de informação para todos os 3 atributos são:

$$Ganho(S_{sunny}, Humidity) = 0.970$$

$$Ganho(S_{sunny}, Temperature) = 0.570$$

$$Ganho(S_{sunny}, Wind) = 0.019$$

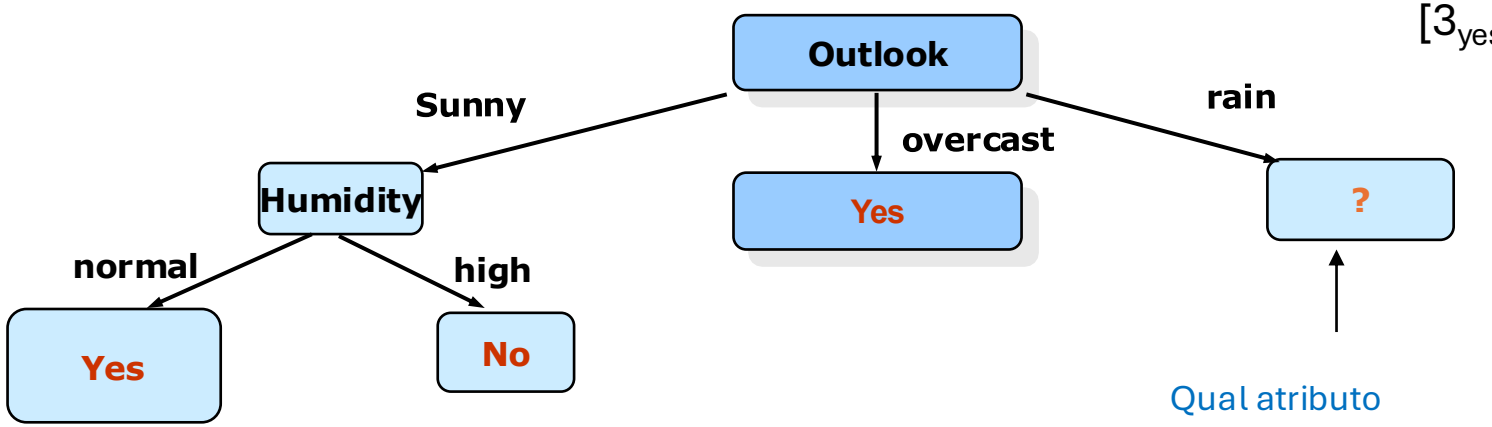
onde S_{sunny} denota a coleção de exemplos de treinamento da tabela dada.

Portanto, Humidity fornece o maior ganho de informação e assim será raiz dessa árvore (subárvore), i.e., Humidity provê a melhor predição do atributo alvo.

Representação de uma Árvore de Decisão

- **Ex**.: A DT for the concept PlayTennis

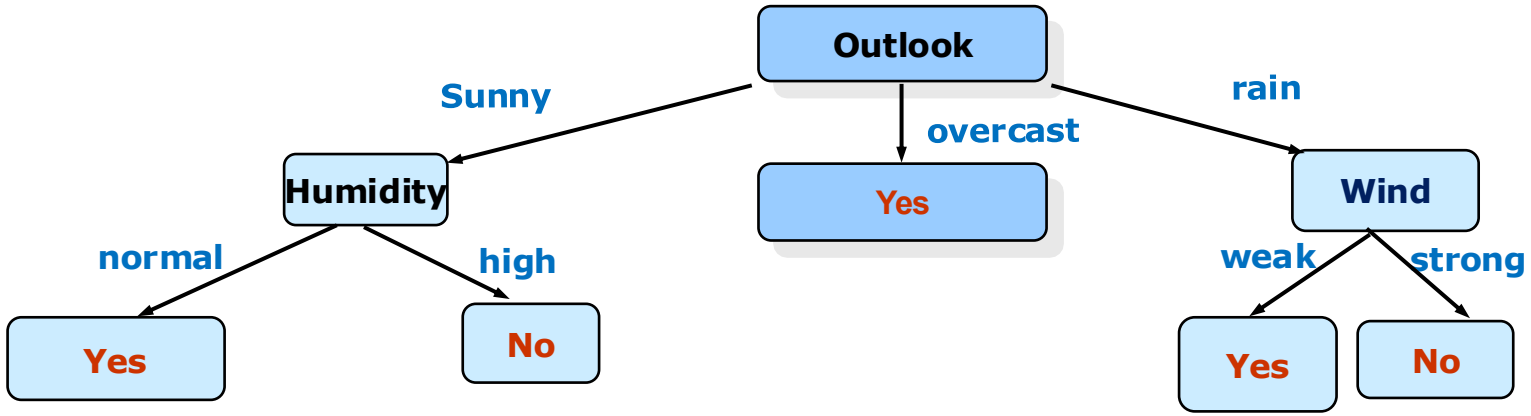
$\{D_4, D_5, D_6, D_{10}, D_{14}\}$
$[3_{yes}, 2_{no}]$



Qual atributo deveria ser testado aqui?

Representação de uma Árvore de Decisão

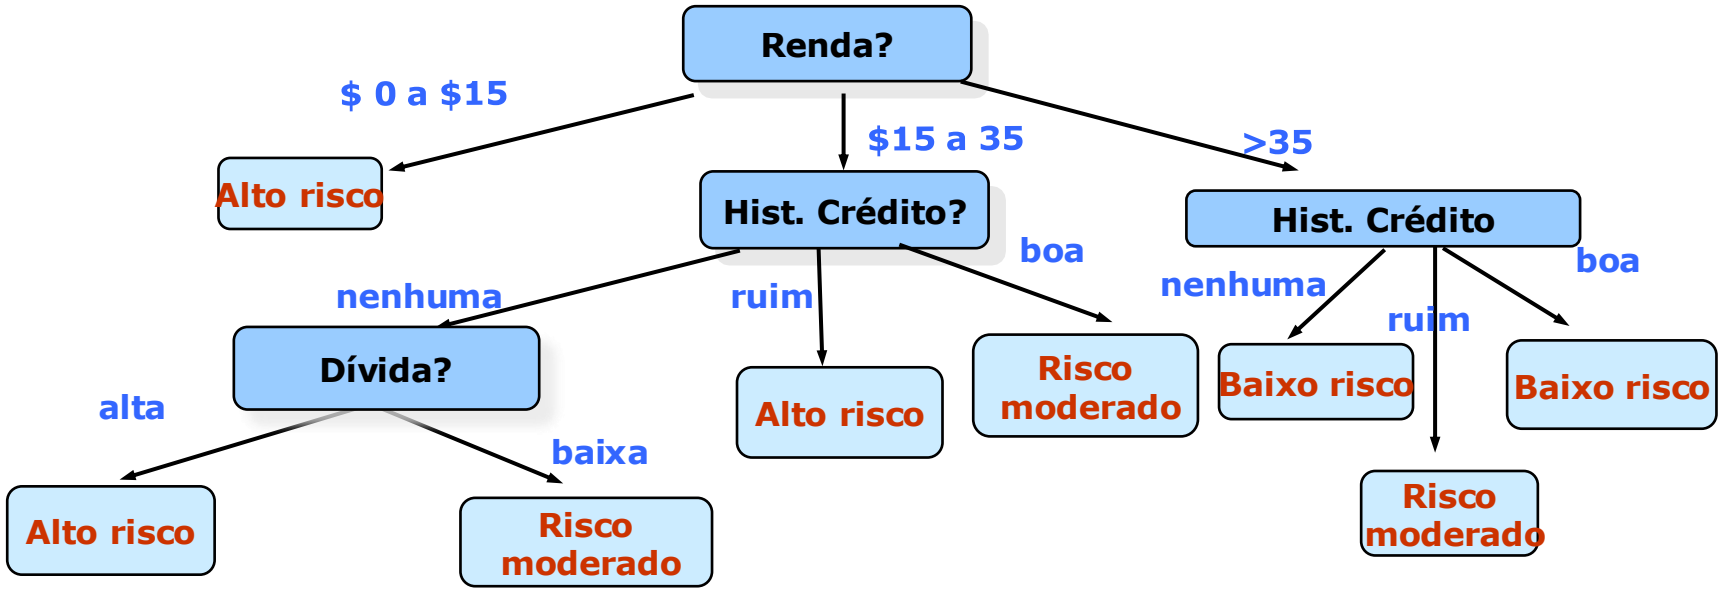
- **Ex**.: A DT for the concept PlayTennis



Voltando para base do Risco de Crédito

Árvore de Decisão

- **Ex**.: Avaliação de Risco de crédito



BASE DE CONHECIMENTO via REGRAS

Se RENDA ∈ 0 a 15K, então RISCO = ALTO
Se RENDA ∈ 15k a 35k e Hist_CRÉDITO = RUIM, então RISCO = ALTO
Se RENDA ∈ 15k a 35k e Hist_CRÉDITO = BOA, então RISCO = MODERADO
Se RENDA ∈ 15K a 35k e Hist_CRÉDITO = DESCONHECIDO e DÍVIDA = ALTA, então RISCO = ALTO
Se RENDA ∈ 15k a 35k e Hist_CRÉDITO = DESCONHECIDO e DÍVIDA = BAIXA, então RISCO = MODERADO
Se RENDA > 35k e Hist_CRÉDITO = RUIM, então RISCO = MODERADO
Se RENDA > 35k e Hist_CRÉDITO = DESCONHECIDO, então RISCO = BAIXO
Se RENDA > 35k e Hist_CRÉDITO = BOA, então RISCO = BAIXO

Indução de Árvore de Decisão

- **Ex.: Conjunto de Exemplos de Avaliação de Risco de crédito:**
- **4 atributos e 3 classes** (Baseado no livro do Luger: IA)

	Risco
E1	Alto
E2	Alto
E3	Moderado
E4	Alto
E5	Baixo
E6	Baixo
E7	Alto
E8	Moderado
E9	Baixo
E10	Baixo
E11	Alto
E12	Moderado
E13	baixo
E14	Alto

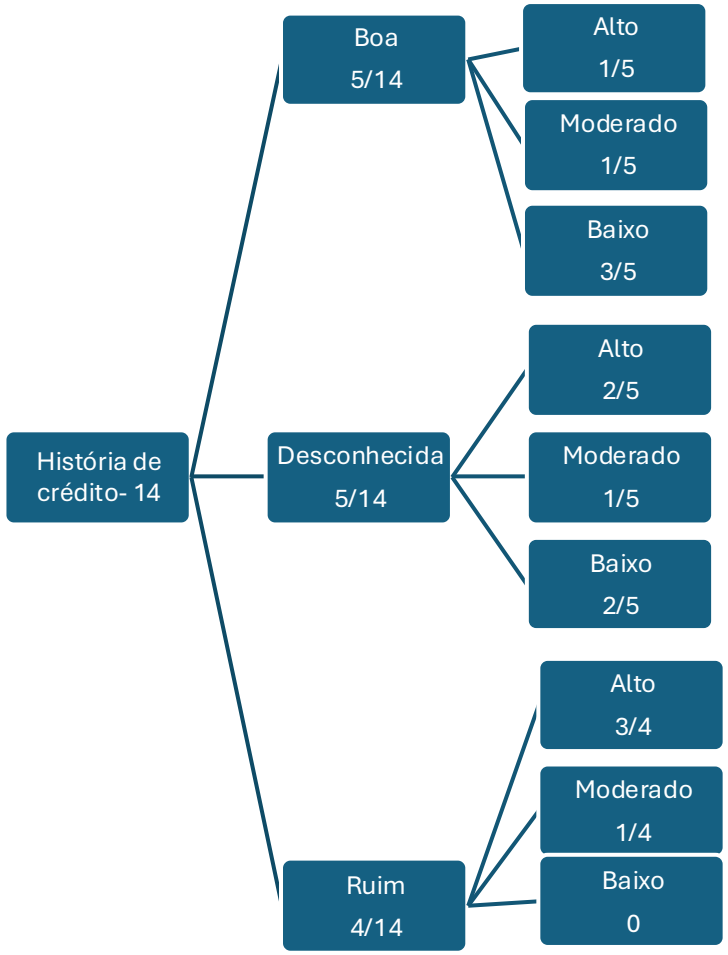
$$Entropy = -\sum_{i=1}^{n} p_i * Log_2(p_i)$$

Entropia (Risco) =

$$info\,(S) = -\frac{6}{14}\log_2\frac{6}{14} - \frac{3}{14}\log_2\frac{3}{14} - \frac{5}{14}\log_2\frac{5}{14} = 1.531$$

História de crédito

História de Crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto



CONTINUAR o processo ...